Artificial Neural Network Applied to The Problem of Secondary Voltage Control

J. Vaschetti, *Member, IEEE* and V. Sauchelli

***Abstract*— This paper presents the design of a controller based on an Artificial Neural Network (ANN) for the problem of the Secondary Voltage Control (SVC) in Electrical Power Systems (EPS). The design is based on the concept of Optimal Power Flow (OPF) and Pilots Nodes (PN), the obtained Controller is applied to a study case in order to validate the result. Finally the influence of various parameters that make the topology of a Neural Network are analyzed.**

***Keywords*—Secondary Voltage Control, Artificial Neural Network, Simulation, Optimal Power Flow, Power Systems.**

I. INTRODUCCION

EN LOS sistemas eléctricos de potencia (SEP) existen dos controles básicos aplicados en distintos niveles espaciales (de aplicación local o global) y temporales (de acción instantánea o diferida), estos son: el control de la tensión en barra y el control de la frecuencia. En el presente trabajo se desarrolla la problemática del Control Secundario de Tensión (SVC) [1], en la Fig. 1 se puede apreciar un diagrama de la estructura jerárquica de dicho control.

Un adecuado perfil de tensiones es necesario para mantener el sistema operando en forma segura, existen una serie de eventos que pueden afectar este perfil, conexiones y desconexiones no programadas de cargas, de generación, de líneas de transmisión, operación incorrecta del sistema, o cualquier otro dispositivo que pueda salir o entrar en servicio en forma programada o no; el elemento de control para mitigar estas contingencias es el reactivo del sistema, el mismo es provisto básicamente por el sistema de generación [2].

Un inadecuado monitoreo y control de la tensión pueden llevar el sistema a un colapso de tensión, lo que ha ocasionado en algunas oportunidades apagones masivos [3]. En los países en desarrollo y en muchos industrializados, el control de la tensión se realiza en forma manual mediante la coordinación conjunta entre el centro de despacho y el operador del sistema de transporte, lo que puede ocasionar una descoordinación o una equivocada operación pudiendo causar el colapso de tensión por eventos en cascada [3].

Países pioneros en el desarrollo del control automático de la tensión fueron Francia e Italia, el esquema propuesto por éstos se basa en un control jerárquico desacoplado en el tiempo y en el espacio utilizando controladores proporcionales e integrales, debido a esto, es que podemos decir que son controladores cuantitativos; dada la compleja relación existente entre los elementos involucrados se ha recurrido a técnicas de Inteligencia Artificial con el objeto de dotar a los controladores de valoraciones cualitativas, en este sentido las redes neuronales constituyen una paso gradual entre la formulación cuantitativa y la cualitativa situándose los sistemas expertos en el extremo descriptivo formal [4].

El objetivo del presente trabajo es retener el concepto jerárquico del control implementando el mismo mediante la utilización de redes neuronales, se presenta un entrenamiento basado en el concepto del flujo óptimo de potencia y se cuantifica la influencia de los distintos parámetros de la red sobre el resultado final del controlador.

J. Vaschetti, FRC, Universidad Tecnológica Nacional, Córdoba, Argentina, jvaschetti@scdt.frc.utn.edu.ar

V. Sauchelli, FCEFyN, Universidad Nacional de Córdoba, Córdoba, Argentina, vsauch@com.uncor.edu

II. CONTROL DE LA TENSIÓN

A. Estructura jerárquica del control de tensión

El control automático de la tensión, Fig. 1, se estructura en tres niveles jerárquicos:

- NVR-TVC (National Voltage Regulation, Tertiary Voltage Control), tiempo de respuesta 5 minutos.
- RVR-SVC (Regional Voltage Regulator, Secondary Voltage Control), tiempo de respuesta 50 segundos.
- AVR (Automatic Voltage Regulator), tiempo de respuesta instantáneo a 0.5 segundos.

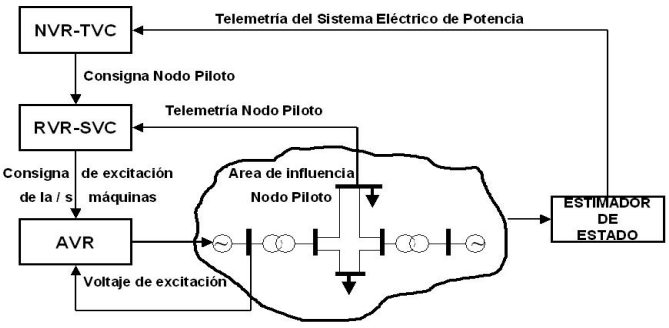


Figura 1. Diagrama jerárquico del Control de Tensión.

Se pueden distinguir en la figura tres niveles de control, un Nivel Terciario de aplicación nacional (NVR-TVC), un Nivel Secundario de aplicación regional (RVR-SVC), y un Nivel Primario de aplicación local (AVR). Estos niveles no solo están distribuidos espacialmente sino que también lo están temporalmente, el Nivel Primario es de actuación inmediata mientras que el Nivel Secundario actúa una vez superado el transitorio del Nivel Primario, del orden del minuto, el Nivel Terciario es el último en actuar y su período se encuentra en el orden de los minutos, tanto el esquema temporal como el espacial tienen que ver con el desacople para evitar

oscilaciones, y ordenes en contrario [1].

B. Selección de los nodos pilotos

La base del sistema está constituida por la elección de nodos pilotos "eléctricamente" dominantes en sus áreas, esto posibilita el manejo acotado de sistemas altamente complejos en cantidad y acoplamiento de variables disminuyendo el orden de las mediciones y de las señales de mando, la idea de un control automático de miles de barras y líneas de transmisión es muy complejo muy critico y puede ser no realista [1], [5].

Para seleccionar los nodos pilotos y las distintas áreas se utilizan los siguientes criterios:

- Los nodos deben ser los mas "fuertes eléctricamente" en su tipo, deben presentar la mayor capacidad de cortocircuito.
- Deben imponer la variación de tensión a los nodos eléctricamente vecinos, la inyección de reactivo en ellos debe traducirse en una variación de tensión también en los nodos eléctricamente próximos.
- El acoplamiento entre los distintos nodos pilotos debe ser mínimo.

Con estas consideraciones es posible prevenir el intercambio de reactivo entre áreas vecinas debido a la acción reguladora del sistema.

La elección de las plantas generadoras para el control deben ser aquellas próximas a los nodos pilotos con la mayor capacidad de reactivo posible, la simple elección de estas plantas ya plantea un subdivisión en áreas [5].

III. FLUJO OPTIMO DE POTENCIA

El Control Secundario de Tensión (SVC) recibe la consigna proveniente del Control Terciario de Tensión (TVC), este último realiza un Despacho Optimo de Potencia (OPF) con el objeto de fijar la referencia de tensión [6], [7].

El problema de obtener el perfil de tensiones adecuado para los nodos pilotos implica la resolución de un proceso de optimización binivel denominado P and Q problems u ORPF (Optimal Reactive Power Flow); el primero de los problemas (P problem) trata del despacho económico de la potencia activa contemplando los costos de generación y se aplica al AGC (Automatic Generation Control), el segundo (Q problem) trata del despacho de la potencia reactiva minimizando las pérdidas en la red (Losses Minimization Control - LMC) y se aplica al SVC (Secondary Voltage Control) y al control manual si no hubiere automático.

Las pérdidas de potencia activa en una red de transmisión están descriptas por la siguiente función:

$$f_Q = \sum_{k\in N_E} P_{kLoss} = \sum_{k\in N_E} g_{ij}(V_i^2 + V_j^2 - 2\,V_i V_j \cos\theta_{ij}) \tag{1}$$

donde

f_Q: Pérdida de potencia activa en la red sujeta al despacho de potencia reactiva.
P_{kLoss}: Pérdida de potencia activa en la rama k.
N_E: Conjunto de todas las ramas de la red.
g_{ij}: Conductancia de la línea de transmisión entre la barra i y la j.
V_i: Voltaje de la barra i.
V_j: Voltaje de la barra j.
θ_{ij}: Diferencia angular de voltaje entre la barra i y la j.
N_B: Conjunto de números de todas las barras.
N_i: Conjunto de números de las barras adyacentes a la i incluida la i.
k: Par ordenado de números (i,j).
i: Subíndice que pertenece a N_B.
j: Subíndice que pertenece a N_i.

La minimización de la ecuación (1) está sujeta al siguiente conjunto de restricciones:

$$\Delta P_i = P_{Gi} - P_{Di} - V_i \sum_{j\in N_i} V_j (G_{ij}\cos\theta_{ij} + B_{ij} sen\theta_{ij}) = 0 \tag{2}$$
$$i \in N_0$$

$$\Delta Q_i = Q_{Gi} - Q_{Di} - V_i \sum_{j\in N_i} V_j (G_{ij} sen\theta_{ij} - B_{ij}\cos\theta_{ij}) = 0 \tag{3}$$
$$i \in N_{PQ}$$

$$V_{imin} \le V_i \le V_{imax} \quad i \in N_B \tag{4}$$

$$Q_{Gimin} \le Q_{Gi} \le Q_{Gimax} \quad i \in \{N_{PV}, n\} \tag{5}$$

$$|Q_k| \le Q_{kmax}, \quad k \in N_E \tag{6}$$

donde

N_0: Conjunto de números de todas las barras excluida la barra de compensación.
N_{PQ}: Conjunto de números de todas las barras tipo PQ.
N_{PV}: Conjunto de números de todas las barras tipo PV.
N: Barra de compensación.

Las restricciones de igualdad (2) y (3) representan el balance de potencia la (3) solo se plantea para las barras PQ para garantizar que no se va a generar más de lo necesario.

La restricción de desigualdad (4) fija el perfil de tensiones de la red mientras que la (5) marca el límite para generar reactivo, por último la (6) fija el límite al reactivo total de la red que incluye los límites de las líneas.

Sea que se utilice una técnica clásica como programación lineal o no clásica como un algoritmo evolutivo para solucionar este problema, la resultante será un perfil de tensiones óptimo que minimiza las pérdidas de activo.

La salida de este procedimiento se utiliza también como consigna de operación para las centrales solo con AVR (Automatic Voltage Regulator), estas centrales son operadas mediante comunicación con los Centros de Control.

IV. CONTROLADOR NEURONAL

A. Esquema de control

En el presente trabajo una red neuronal es entrenada para controlar el nivel de tensión en los nodos pilotos fijando la referencia de tensión en el AVR de cada generador que participa en el control secundario de tensión, Fig. 2, [8].

El juego de datos para entrenar la red neuronal se obtiene sometiendo el sistema a distintas perturbaciones y resolviendo luego el flujo óptimo que resulta para la nueva situación.

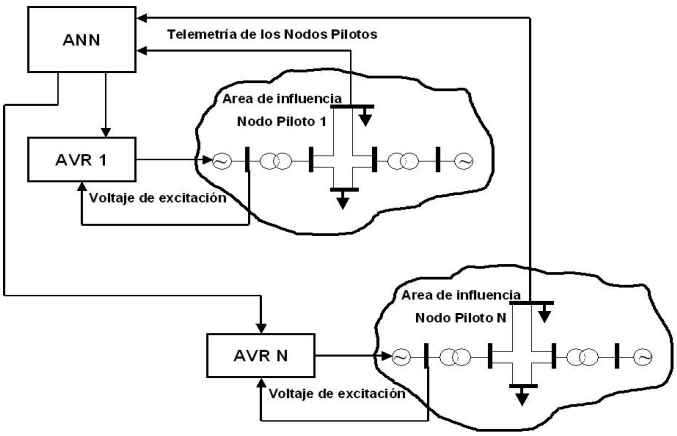


Figura 2. Esquema de control para el sistema eléctrico de potencia utilizando un controlador basado en redes neuronales artificiales (ANN).

El problema de estabilidad estática del voltaje como control secundario de la tensión de un sistema de potencia operando en régimen permanente queda resumido a un regulador como el de la Fig. 3 con la siguiente consigna: Corregir el nivel de tensión del nodo piloto ante un desvío ocasionado por una perturbación modificando la consigna de tensión de la barra del generador. La red neuronal debe aprender la relación funcional equivalente a la solución del flujo óptimo de potencia planteado en las ecuaciones (1) a (6).

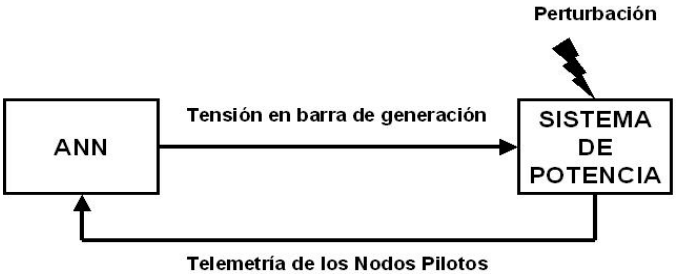


Figura 3. Control secundario para la estabilidad estática de la tensión del sistema eléctrico de potencia en régimen permanente.

B. Estructura de la red neuronal

Para definir la estructura de una red neuronal es necesario establecer una serie de valores para distintos componentes, algunos de estos parámetros quedan definidos por el proceso que se quiere controlar. Para el caso bajo análisis el número de entradas y salidas queda establecido ambos en tres. Algunas cuestiones quedan al día de hoy como trabajo de investigación no poseyéndose un criterio analítico exacto para su respuesta, tal es el caso de la cantidad de neuronas en la capa oculta así como el número de capas ocultas [8].

Otros temas como el mecanismo de entrenamiento tienen que ver con el tiempo que insume el mismo, con la memoria de máquina que utiliza con la capacidad de converger a un mínimo local, etc; por último las funciones de activación se asocian con la capacidad para aproximar funciones no lineales, como es el caso del Flujo Optimo de Potencia (OPF), y con el algoritmo de entrenamiento (condición de derivabilidad). En la Tabla I se resume la estructura de la red propuesta, el criterio seguido para la formulación es el denominado Ockham's Razor [9]; en la sección VI se tratará con mas detalle esta propuesta. En la Fig. 4 se presenta una estructura simplificada del Perceptrón Multi Capa (MLP) el cual es empleado como aproximador universal de funciones [9], ver Teorema de Funahashi [15].

TABLA I
ESTRUCTURA DEL CONTROLADOR NEURONAL

Componente	Valor
Número de neuronas de entrada	3
Número de neuronas de salida	3
Número de capas ocultas	1
Número de neuronas en la capa oculta	12
Función de activación de la capa oculta	tansig
Función de activación de la capa de salida	purelin
Algoritmo de entrenamiento	trainlm

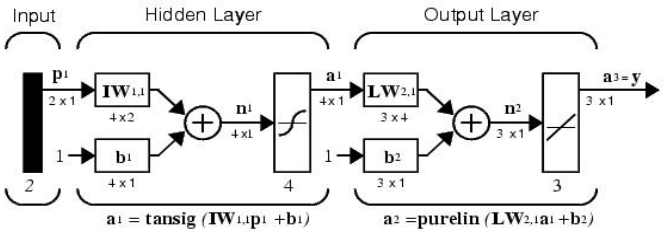


Figura 4. Estructura simplificada del perceptrón multi capa.

Para ajustar los coeficientes de la red se ha utilizado el algoritmo de entrenamiento de Levenberg-Marquardt Backpropagation (LMBP, trainlm) [9], este algoritmo ha sido aplicado con mucho éxito y para redes de cientos de coeficientes es muy rápido sobre todo si se exige alta precisión, además es de fácil implantación en Matlab® por su estructura matricial [13].

El algoritmo LMBP es un método de optimización que toma lo mejor de Gauss-Newton que es la velocidad de convergencia y la garantía de convergencia que da el método del descenso por la máxima pendiente. Una característica fundamental del LMBP es que tiene un modo de entrenamiento por lote (batch) todos los pares de entrada-salida son presentados a la red calculando un índice de performance que es la suma cuadrática de los errores de cada par, luego de este proceso se actualizan hacia atrás los coeficientes, la función índice depende de los coeficientes de la red, los ajustes se van produciendo con el objeto de minimizar la función, si el valor de la función de optimización satisface un determinado error se detiene el proceso de entrenamiento de lo contrario se vuelve a presentar el conjunto entrada-salida realizando un nuevo ajuste de coeficientes.

Sea la función de optimización siguiente:

$$F(\mathbf{x}) = \sum_{q=1}^{Q} \mathbf{e}_q^T(\mathbf{x})\,\mathbf{e}_q(\mathbf{x}) = \sum_{q=1}^{Q} (\mathbf{t}_q - \mathbf{y}(\mathbf{x})_q)^T (\mathbf{t}_q - \mathbf{y}(\mathbf{x})_q) \quad (7)$$

donde

x	Conjunto de coeficientes de la red neuronal, pesos (**W**) y polarizaciones (**b**).
e	Vector error.
p,t	Vector par de entrada-salida provisto para el entrenamiento.
y	Vector de salida entregado por la red neuronal.
Q	Conjunto de todos los datos de entrenamiento.

El incremento de los coeficientes en la iteración (k+1) se obtiene mediante la siguiente expresión:

$$\mathbf{x}_{k+1} = \mathbf{x}_k - \left[\mathbf{J}^T(\mathbf{x}_k)\mathbf{J}(\mathbf{x}_k) + \mu_k \mathbf{I}\right]^{-1} \mathbf{J}^T(\mathbf{x}_k)\mathbf{e}(\mathbf{x}_k) \quad (8)$$

donde

J	Jacobiano de la función de optimización con respecto a los coeficientes de la red neuronal.
I	Matriz identidad.
μ_k	Tasa de aprendizaje en la iteración k, ajustable.

Siendo el incremento de los coeficientes

$$\Delta\mathbf{x}_k = \left[\mathbf{J}^T(\mathbf{x}_k)\mathbf{J}(\mathbf{x}_k) + \mu_k \mathbf{I}\right]^{-1} \mathbf{J}^T(\mathbf{x}_k)\mathbf{e}(\mathbf{x}_k) \quad (9)$$

El algoritmo queda estructurado de la siguiente manera:

Paso 1: Inicializar los pesos **W** y las polarizaciones **b** en forma aleatoria y fijar la tasa de aprendizaje μ (μ = 0.01 es un valor apropiado).

Paso 2: Fijar un criterio de parada en base a un valor satisfactorio de la función de optimización, a un número de epochs (Veces que ha sido presentado el conjunto entrada-salida para el entrenamiento), o a un valor predeterminado del gradiente.

Paso 3: Presentar todo el conjunto de entradas $\mathbf{p}_q$ a la red y computar los conjuntos de salida $\mathbf{y}_q$, evaluar el conjunto de errores $\mathbf{e}_q$. Computar la función de optimización $F(\mathbf{x})$.

Paso 4: Computar el Jacobiano y resolver (9).

Paso 5: Recalcular la función de optimización utilizando $\mathbf{x}_k + \Delta\mathbf{x}_k$. Si este valor es menor al obtenido en el **Paso 3**, disminuir μ dividiéndolo por un valor β (p. Ej. β = 10), hacer $\mathbf{x}_{k+1} = \mathbf{x}_k + \Delta\mathbf{x}_k$ y retornar al **Paso 2**. Si la función de optimización no se reduce, entonces multiplicar μ por β y retornar al **Paso 4**.

La manipulación de μ en el último paso regula el comportamiento del algoritmo entre el método de Gauss-Newton o el del descenso por máxima pendiente, si no se consigue una disminución del error se disminuye la velocidad de convergencia asegurándose la misma (descenso por máxima pendiente), de lo contrario se acelera el paso.

V. SIMULACIÓN

A. Caso de Estudio

Con el objeto de aplicar los conceptos desarrollados precedentemente se selecciona el caso de estudio presentado en la Fig.4 [10], [11].

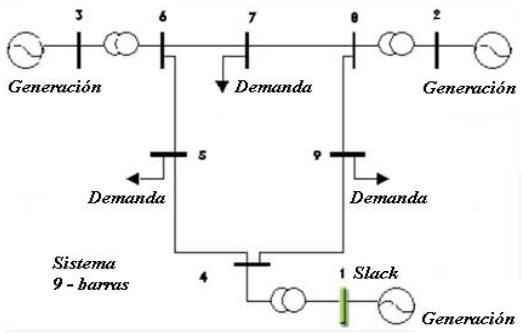


Figura 4. Sistema de 9 barras y 3 generadores.

Las barras 5, 7 y 9 se toman como nodos pilotos, mientras que las 1, 2 y 3 son de control.

El algoritmo para generar los datos basado en flujo óptimo de potencia, la simulación de la red neuronal y su entrenamiento son simulados utilizando la plataforma Matlab® en particular se hace uso del Neural Network Toolbox™ [13].

B. Generación de datos

Para entrenar la red neuronal se genera un conjunto de datos a partir de tres escenarios básicos, Valle (50% de la demanda), Resto (75%), y Pico (100%), sobre estos escenarios se perturba el sistema en forma aleatoria generando escalones de demanda que van desde el 20% al 150% del caso base, en la Fig. 5 se puede apreciar el diagrama de flujo del algoritmo.

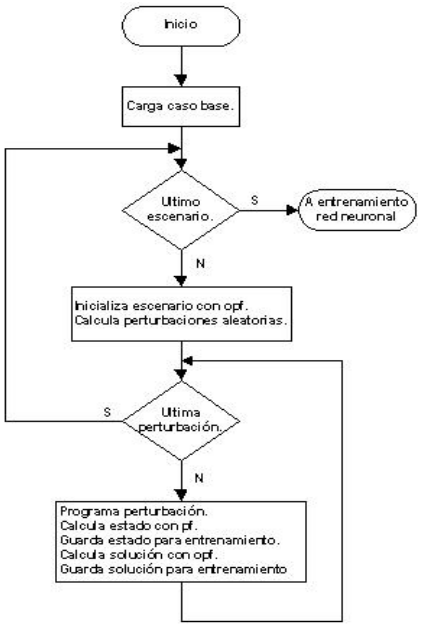


Figura 5. Diagrama de Flujo para generación de datos.

Utilizando este algoritmo se generan 300 parejas de datos, 100 por cada escenario destinándose el 50% de ellos al entrenamiento, el 25% a la validación y el resto a la etapa de prueba [14].

Hay que tener en cuenta que un entrenamiento debe contemplar todas las posibles contingencias y no solamente las referidas a la carga [12].

El cálculo mediante el uso de Flujo de Potencia (pf) permite obtener el valor de tensión en los nodos pilotos ante la perturbación, mientras que el Flujo Optimo de Potencia (opf) entrega la solución para la corrección de las variables de control, se forma así una pareja entrada – salida apta para el entrenamiento de la red neuronal.

C. Resultado de simulación

Para probar la eficacia del controlador se generan dos nuevas contingencias las cuales no forman parte de los datos de entrenamiento.

Caso I: Sobre la base de un escenario del 80% de la carga se simula un decremento al 30% de la misma, el sistema está totalmente conectado los resultados se muestran en la Tabla II.

En este caso el escenario planteado se encuentra dentro del dominio de los datos que se usaron para entrenamiento. El sistema se encuentra operando en un estado de carga alto, como consecuencia del intempestivo decremento de la misma los nodos pilotos reflejan esta contingencia aumentando su tensión por encima del valor permitido de 1.05 pu. La solución que entrega el flujo óptimo de potencia es coincidente con la entregada por la red neuronal, si se consideran cuatro cifras significativas el índice de eficiencia pérdidas de activo (P_{loss}), es igual.

Caso II: Similar al anterior, el escenario inicial es del 30% de la carga y la contingencia representa un incremento al 150%, los resultados también se muestran en la Tabla II.

Aquí el escenario planteado está fuera del dominio de entrenamiento con lo cual se puede probar la capacidad de generalización de la red neuronal. Al estar el sistema descargado y sufrir un intempestivo aumento de la demanda los nodos pilotos V5 y V9 disminuyen su tensión por debajo del límite permitido de 0.95 pu. La respuesta del controlador neuronal es equivalente a la entregada por el flujo óptimo salvo una pequeña diferencia en la referencia V3 esto se ve reflejado en el índice de eficiencia.

Caso III: Similar a los anteriores solo que aquí se ha tomado como nodo piloto solamente la barra 9. Esta barra presenta la mayor potencia de cortocircuito del sistema por lo tanto la mínima impedancia y por consiguiente la mayor sensibilidad ante las variaciones de generación. Se aprecia una pequeña variación en la solución que entrega la red neuronal con respecto al flujo óptimo de potencia, esta pequeña variación se ve más que compensada con la reducción del sistema de telemetría y control.

TABLA II
RESULTADO DE LA SIMULACION ANTE PERTURBACION DE CARGA

	Caso I			Caso II			Caso III		
	Inicial	OPF	ANN	Inicial	OPF	ANN	Inicial	OPF	ANN
Variables de control									
V1	1.045	1.017	1.017	1.017	1.050	1.050	1.017	1.050	1.050
V2	1.044	1.029	1.029	1.029	1.050	1.050	1.029	1.050	1.049
V3	1.035	1.025	1.025	1.025	1.050	1.049	1.025	1.050	1.049
Nodos pilotos									
V5	1.058	1.049	1.049	0.928	0.993	0.993	0.928	0.993	0.992
V7	1.064	1.050	1.050	0.967	1.011	1.011	0.967	1.011	1.010
V9	1.052	1.044	1.044	0.905	0.968	0.968	0.905	0.968	0.967
Indice de eficiencia									
Ploss		0.461	0.461		8.734	8.739		8.734	8.746

VI. INFLUENCIA DE LOS PARAMETROS DE RED

A. Introducción

Fijados los aspectos básicos de la red neuronal que sintetizan el controlador según los criterios expuestos en la sección IV.*B*, queda por analizar la influencia de los distintos componentes sobre el rendimiento del controlador. Se utilizan distintos índices para medir la influencia, velocidad de convergencia, tiempo de entrenamiento, minimización de pérdidas, y capacidad de generalización, un combo de todos ellos señala una estructura óptima.

B. Cantidad de neuronas en la capa oculta

Uno de los aspectos que al día de hoy no puede ser cuantificado con exactitud es el número de neuronas que se necesitan en la capa oculta para un determinado problema [8], [9]. Si se utiliza un número pequeño de neuronas puede que no se logre sintetizar la función, por otro lado si el número de neuronas en la capa oculta es demasiado grande la red puede memorizar los puntos de entrenamiento y luego perder capacidad de generalización.

En [16], [17], [18] se sugieren distintas expresiones para determinar la cantidad de neuronas en la capa oculta, una de ellas es la presentada en (10).

$$m_h^l = \frac{2}{3}(n+m) \tag{10}$$

donde

m_h^l Cantidad de neuronas en la capa oculta.

n Cantidad de entradas.

m Cantidad de salidas.

Para el caso bajo análisis la ecuación (10) entrega un valor de cuatro, definiendo una topología 3:4:3 en lugar de la 3:12:3 utilizada en el presente trabajo.

Existen otros criterios más genéricos a la hora de definir la cantidad de neuronas que debe tener la capa oculta, a continuación algunos de ellos:

- El número de neuronas en la capa oculta debe estar entre la cantidad de entradas y las de salidas.
- El número de neuronas en la capa oculta debe estar en el orden dado por $m_h^l = c.\sqrt{m.n}$, siendo c un coeficiente que depende de la naturaleza de la aplicación.

- El número de neuronas en la capa oculta debe ser menor que el doble de entradas.

Todas estas consideraciones sirven como punto de partida. En la Fig. 6 se aprecia el diagrama de flujo que representa el mecanismo que se ha seguido en el presente trabajo para determinar la cantidad de neuronas necesarias en la capa oculta, este razonamiento se conoce como selección hacia adelante (forward selection), el número de partida es el proporcionado por la ecuación (10).

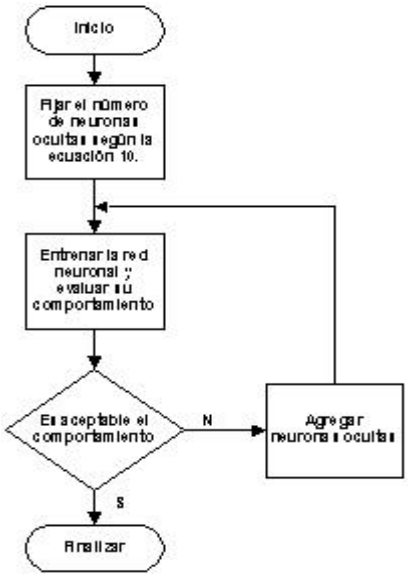


Figura 6. Mecanismo para determinar el número de neuronas en la capa oculta.

Se aplican tres criterios para determinar el comportamiento de la red neuronal:

- La convergencia en términos del error propuesto y la velocidad de entrenamiento en función de los epochs.
- Análisis post-entrenamiento mediante regresión lineal.
- Capacidad para generalizar el Caso II el cual se encuentra fuera del dominio de entrenamiento.

Los parámetros de entrenamiento son los siguientes:

- Learning rate 0.05.
- Epochs 300.
- MSE 1x10 $^{-6}$.

La Fig. 7.a muestra la convergencia para el caso de cuatro neuronas en la capa oculta, luego de varios intentos no logra alcanzar el valor mínimo de la función de optimización generalmente concluye por validación.

La Fig. 7.b muestra los parámetros de convergencia para el modelo propuesto con doce neuronas en la capa oculta. Siempre que se intenta el entrenamiento éste concluye con éxito, se hace notar el número de epochs que insume el ajuste de coeficientes.

En las Fig. 8.a y 8.b se presenta el estudio de regresión lineal. Para ambos casos se puede apreciar la capacidad de generalización del controlador con doce neuronas por sobre el de cuatro neuronas, esto se manifiesta en los valores que sugiere el controlador para el AVR los cuales se presentan en la Tabla III, se debe tener en cuenta que el valor máximo de tensión permitido en un nodo es de 1.05 pu.

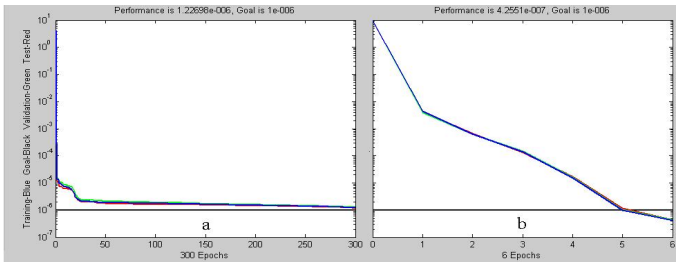


Figura 7. Convergencia, a)cuatro neuronas en la capa oculta y b) doce neuronas.

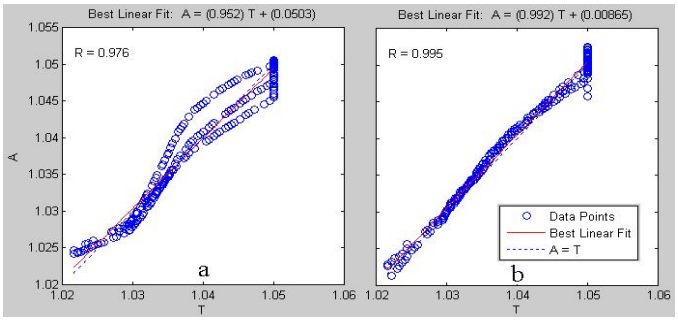


Figura 8. Estudio de regresión lineal sobre la coordenada V9, a) cuatro neuronas en la capa oculta, coeficiente de correlación 0.976, b) doce neuronas, coeficiente de correlación 0.995.

TABLA III

VALORES DE CONTROL PARA EL AVR SEGÚN LA CANTIDAD DE NEURONAS EN LA CAPA OCULTA

	Caso II			
	Inicial	OPF	4xANN	12xANN
Variables de control				
V1	1.017	1.050	1.052	1.050
V2	1.029	1.050	1.052	1.050
V3	1.025	1.050	1.056	1.049

C. Cantidad de capas ocultas y funciones de activación

Admitiendo que el diseño de una red neuronal tiene mucho de prueba y error se reconocen algunos aspectos a tener en cuenta que tienen influencia sobre la estructura de la red y de difícil consideración analítica tales como:

- La dimensión del espacio a tratar.
- La complejidad de la función a modelar.
- El número de puntos de entrenamiento.
- La distribución espacial de los datos.
- La presencia de ruido en los datos de entrada.

Uno de los temas menos tratado en la bibliografía es precisamente la cantidad de capas ocultas que se necesitan; los

esfuerzos se centran en evitar el sub y sobre ajuste así como obtener la mejor generalización recurriendo al número óptimo de neuronas en la capa oculta y al algoritmo de entrenamiento como solución.

Se da por sentado en base a teoremas como el de Funihashi [15] que el Perceptrón Multicapa con una capa oculta basada en la función de activación sigmoidea y una capa de salida con función de activación lineal tiene la capacidad de aproximar cualquier función por compleja que ésta sea [19]. Se debe tener presente el criterio de Ockham, la red debe ser lo más sencilla posible sobre todo si la dimensión del problema es grande y la cantidad de patrones para entrenamiento es limitado, en este caso la cantidad de coeficientes debe ser la menor posible con el objeto de evitar la memorización y por consiguiente la pérdida de generalización.

VII. CONCLUSIONES

En el presente trabajo se ha mostrado la capacidad del Perceptrón Multicapa para controlar el nivel secundario de tensión en los nodos pilotos ante perturbaciones de carga. La propuesta del Flujo Optimo de Potencia como algoritmo de entrenamiento proporciona la cantidad de datos necesarios para el entrenamiento eficaz, a la vez que otorga funcionalidades del tercer nivel de control al nivel dos. Se ha estudiado también la cantidad óptima de neuronas en la capa oculta y se ha mostrado que partiendo de un criterio analítico orientativo se puede arribar a una solución óptima con el método de selección hacia adelante.

Debe tenerse en cuenta que el entrenamiento debe repetirse para evitar la optimización sobre un mínimo local. En este trabajo se ha usado un caso fuera del dominio de entrenamiento para verificar la capacidad de generalización de la red. Por último debe considerarse el entrenamiento sobre todas las posibles contingencias con el fin de que el controlador pueda manejarlas.

REFERENCIAS

[1] S. Corsi, M. Pozzi, C. Sabelli, A. Serrani; "The Coordinated Automatic Voltage Control of the Italian Transmission Grid—Part I: Reasons of the Choice and Overview of The Consolidated Hierarchical System", *IEEE Transaction on Power Systems*, vol. 19, Nº 4, pp. 1723-1732. November 2004.

[2] P. Kundur; *Power System Stability and Control*; EPRI (Electric Power Research Institute), 1994, 1167 pgs.

[3] M. Ilic, F. Wu; "Research an Applications on Real-Time Control of Power Grids: Past Successes and Future Opportunities", *Bulk Power System Dynamics and Control – VI*, Cortina D'Ampezzo, pp. 758-769; August 2004.

[4] M. A. Laughton; "Artificial Intelligence Techniques in Power Systems"; *(Digest No: 1997/354), IEE Colloquium on*, 3 Nov.1997 Pages:1/1 – 1/19.

[5] A. Danelli, G. B. Denegri, M. Invernizzi, M. Pozzi, P. Serra; "Electric Power System Monitoring: Phenomenon Independent Positioning of a Constrained Number of PMUs"; *Bulk Power System Dynamics and Control - VI*; Cortina D'Ampezzo; August 2004.

[6] A. Gomez Expósito; *Análisis y operación de sistemas de energía eléctrica;* McGraw-Hill Interamericana de España, 2002, 769 pgs.

[7] S. Salamat Sharif, J. Taylor, E. Hill; "On-Line Optimal Power Flow by Energy Loss Minimization"; *Proc. 35 IEEE Conference on Decision and Control*, Kobe, Japan, December 1996.

[8] M. R. Khaldi; "Neural Networks and Static Voltage Stability in Power Systems"; *Industrial Technology, 2008. ICIT 2008. IEEE International Conference on*; Chengdu, China, April 2008.

[9] M. T. Hagan, H. B. Demuth and M. Beale, *Neural Network Design,* PWS Publishing Company, Boston, MA, United States, 1996.

[10] P. W. Sauer and M. A. Pai, *Power system dynamics and stability*, Prentice-Hall, New Jersey, 1998, 357 pgs.

[11] P.M. Anderson & A.A. Fouad, *Power Systems Control and Stability 2nd ed*, Wiley-Interscience, IEEE Press, 2033, 650 pgs.

[12] R. Murray-Smith, D. Neumerkel, D. Sbarbaro-Hofer, "Neural Networks for Modelling and Control of a Non-Linear Dynamic System", *IEEE International Symposium on Intelligent Control,* 11-13 August 1992, Glasgow, Scotland.

[13] http://www.mathworks.com/products/neuralnet/

[14] W. S. Sarle, "Stopped Training and Other Remedies for Overfitting", *Proceedings ot the 27th Symposium on the Interface of Computing Science and Statistics,* pp. 352-360, Fairfax Station, VA, United States, 1995.

[15] K. Funahashi, "On the approximate realization of continuous mapping by neural networks", *Neural Networks*, Vol. 2, pp. 183-192, 1989.

[16] S. Lawrence, C. L. Giles, and A. C. Tsoi, "What Size Neural Network Gives Optimal Generalization? Convergence Properties of Backpropagation". U. of Maryland Technical Report CS-TR-3617.

[17] M. Hayashi, "A fast algorithm for the hidden units in a multilayer perceptron", *Neural Networks, 1993. IJCNN '93-Nagoya. Proceedings of 1993 International Joint Conference on,* Vol. 1, pp. 339-342, Nagoya, Japan, 25-29 Oct. 1993.

[18] E. J. Teoh, K. C. Tan, and C. Xiang, "Estimating the Number of Hidden Neurons in a Feedforward Network Using the Singular Value Decomposition," *IEEE Transactions on Neural Networks*, Vol. 17, No. 6, pp. 1623-1629, November 2006.

[19] B. Martín del Brío, A. Sanz Molina, *Redes Neuronales y Sistemas Difusos*, RA-MA, Madrid, España, 2002, 399 pgs.



Jorge Vaschetti recibió el grado de Ingeniero en Electrónica en la Universidad Tecnológica Nacional. Actualmente es postulante al Doctorado en Ciencias de la Ingeniería por la Universidad Nacional de Córdoba. Se desempeña como Investigador Principal en el Grupo de Investigación sobre Calidad de Potencia del Departamento de Ingeniería Eléctrica de la UTN donde es profesor dedicación exclusiva por concurso e investigador categoría "B" y categoría III de la CONEAU. Actualmente sus investigaciones se concentran en el área del Control Inteligente aplicado a los Sistemas Eléctricos de Potencia.



Víctor Hugo Sauchelli, recibió el título de grado en Electricidad y Electrónica de la Universidad Nacional de Córdoba, Facultad de Ciencias Exactas Físicas y Naturales (UNC – FCEFyN), la Especialización en la UTN, FRC y el Doctorado en Ciencias, mención electrónica en la UNC – FCEFyN . Director del laboratorio de Investigacion Matemática Aplicada al Control (LIMAC) de la UNC- FCEFyN, desarrollando temas vinculados a series temporales, redes neuronales como filtro y controladores de orden fraccional. Es profesor Titular de la asignatura de Sistemas de Control II (digitales) y de Teoría de Señales, con dedicación Exclusiva y está categorizado en el programa de Investigadores de la SCyT de la UNC, (Coneau) con categoría II